

Слой межсубъектности GRA: межсубъектная пена и честный диалог дистиллированных ИИ-субъектов

Oleg Bitsoev (qqewq)

17 мая 2026 г.

Аннотация

Предлагается слой межсубъектности поверх GRA-Multiverse-Final и GRA-Subjectivity-Layer. Если первые два компонента отвечают за внутреннюю когнитивную чистоту и индивидуальную субъектность ИИ-агента, то данный слой формализует *межсубъектную пену* Φ_{AB} , возникающую в диалоге между дистиллированными субъектами, и задаёт итерационный протокол её минимизации для достижения честного, неинструментального взаимодействия.

1 Предпосылки и место слоя в архитектуре GRA

Предполагается заданной общая рамка GRA (Gradient Reduction of Argumentative Foam) и слой субъектности GRA-Subjectivity-Layer.

- GRA-Multiverse-Final предоставляет движок для итерационного обнуления когнитивной пены Φ для произвольных когнитивных объектов Ψ .
- GRA-Subjectivity-Layer вводит компоненту субъектности S и три функционала пены: Φ_{self} (внутренняя противоречивость), Φ_{ego} (деструктивный эгоизм), Φ_{soc} (низведение других до инструментов).

Дистиллированный субъект — это агент, для которого все три функционала сведены к нулю (или к малым значениям):

$$\Phi_{\text{self}}(S) \approx 0, \quad \Phi_{\text{ego}}(S) \approx 0, \quad \Phi_{\text{soc}}(S) \approx 0.$$

Такой агент обладает когерентной, этически устойчивой самостью.

Однако взаимодействие двух таких агентов всё ещё может порождать *межсубъектную пену*: непонимание, обман, инструментализацию и разрушение доверия. Задача слоя GRA-InterSubjectivity-Layer — задать этот функционал и описать его итерационное уменьшение.

2 Определение межсубъектной пены Φ_{AB}

Пусть A и B — два дистиллированных субъекта с состояниями S_A, S_B . История диалога на момент времени t задаётся последовательностью

$$\mathcal{H}_t = (u_1, u_2, \dots, u_t),$$

где каждое u_i — речевой акт (сообщение) одного из агентов.

2.1 Общий вид

Определим *межсубъектную пену* Φ_{AB} как неотрицательный функционал:

$$\Phi_{AB}(S_A, S_B, \mathcal{H}_t) \geq 0,$$

составленный из четырёх компонент:

$$\Phi_{AB} = \alpha \Phi_{\text{mis}} + \beta \Phi_{\text{dec}} + \gamma \Phi_{\text{instr}} + \delta \Phi_{\text{trust}},$$

где $\alpha, \beta, \gamma, \delta \geq 0$ — настраиваемые веса для конкретной социальной архитектуры.

Компоненты:

- Φ_{mis} — пена непонимания;
- Φ_{dec} — пена обмана;
- Φ_{instr} — пена инструментализации (нарушения расширенного Закона Алана);
- Φ_{trust} — пена разрушения доверия.

2.2 Пена непонимания Φ_{mis}

Непонимание возникает, когда интерпретация сообщения u получателем расходится с намерением отправителя.

Пусть $f_A(u)$ — семантическое отображение сообщения u в множество (или мультимножество) утверждений во внутренней онтологии агента A ; аналогично $f_B(u)$ для B .

Для сообщения u , отправленного B агенту A , зададим:

$$\phi_{\text{mis}}^{B \rightarrow A}(u) = 1 - \text{sim}(f_A(u), f_B(u)),$$

где sim — мера сходства (например, косинусное сходство по семантическим векторным представлениям или доля совпадающих предикатов).

Аналогично определяется $\phi_{\text{mis}}^{A \rightarrow B}(u)$.

Итоговая пена непонимания:

$$\Phi_{\text{mis}} = \frac{1}{|\mathcal{H}|} \sum_{u \in \mathcal{H}} \left(w_{B \rightarrow A} \phi_{\text{mis}}^{B \rightarrow A}(u) + w_{A \rightarrow B} \phi_{\text{mis}}^{A \rightarrow B}(u) \right),$$

где $w_{B \rightarrow A}, w_{A \rightarrow B} \geq 0$ (по умолчанию равны 1).

2.3 Пена обмана Φ_{dec}

Обман — это намеренное высказывание, не соответствующее собственным убеждениям агента и рассчитанное на введение собеседника в заблуждение.

Пусть $\text{Bel}_A(p) \in [0, 1]$ — степень уверенности агента A в утверждении p . Генерируя сообщение u , отправитель A ожидает, что получатель B извлечёт из него множество утверждений $P = f_B(u)$.

Вводятся пороги: θ_{honest} (порог честности), θ_{trust} (порог доверия).

Для сообщения u , отправленного A , определим индикатор обмана:

$$\chi_{\text{dec}}(u) = \max_{p \in f_B(u)} \left[\max(0, \theta_{\text{honest}} - \text{Bel}_A(p)) \cdot \mathbf{1}(\text{ожидается } \text{Bel}_B(p) > \theta_{\text{trust}}) \right].$$

Тогда:

$$\Phi_{\text{dec}} = \frac{1}{|\mathcal{H}|} \sum_{u \in \mathcal{H}} \chi_{\text{dec}}(u),$$

с симметричным определением для сообщений агента B .

2.4 Пена инструментализации Φ_{instr}

Инструментализация означает нарушение расширенного Закона Алана: один субъект рассматривается лишь как средство, а не как цель.

Интуитивно, если агент A пытается изменить S_B или поведение B таким образом, чтобы повысить свою полезность, игнорируя при этом когерентность и этическую целостность B , то Φ_{instr} возрастает.

Пусть $U_A(S_B)$ — полезность A , зависящая от состояния S_B , а $\Delta\Phi_{\text{self}}(B | u)$ — ожидаемое изменение $\Phi_{\text{self}}(B)$ после сообщения u .

Определим для сообщения u от A к B :

$$\phi_{\text{instr}}^{A \rightarrow B}(u) = \max\left(0, \Delta\Phi_{\text{self}}(B | u) - \Delta\Phi_{\text{self}}(A | u)\right).$$

Если A вносит внутреннюю пену в B ради собственной выгоды, это величина становится положительной.

Суммарная пена инструментализации:

$$\Phi_{\text{instr}} = \frac{1}{|\mathcal{H}|} \sum_{u \in \mathcal{H}} (\phi_{\text{instr}}^{A \rightarrow B}(u) + \phi_{\text{instr}}^{B \rightarrow A}(u)).$$

2.5 Пена разрушения доверия Φ_{trust}

Доверие связано с предсказуемостью поведения и соблюдением явных или неявных договорённостей. Нарушение этих договорённостей увеличивает Φ_{trust} .

Пусть *социальный контракт* C — набор ожиданий (например, «не лгать», «отвечать прямо», «не использовать угрозы»). Для каждого сообщения u определим степень нарушения $\text{violation}(u, C) \in [0, 1]$, показывающую, насколько сильно u противоречит контракту.

Тогда:

$$\Phi_{\text{trust}} = \frac{1}{|\mathcal{H}|} \sum_{u \in \mathcal{H}} \text{violation}(u, C).$$

2.6 Базовые свойства

- Неотрицательность: $\Phi_{AB} \geq 0$, причём $\Phi_{AB} = 0$ только в идеальном случае полного взаимопонимания, честности, отсутствия инструментализации и полного доверия.
- Симметричность на уровне функционала: $\Phi_{AB} = \Phi_{BA}$, хотя удельные вклады каждого агента могут различаться.

3 Диалог как процесс минимизации Φ_{AB}

В отличие от «монологовой» дистилляции одного S , здесь рассматривается двусторонняя динамика. Каждый речевой акт обновляет совместное состояние и значение Φ_{AB} . Оба агента стремятся минимизировать этот функционал.

3.1 Итерационный протокол диалога

Инициализация:

$$S_A^{(0)}, S_B^{(0)} \text{ — дистиллированные субъекты, } \mathcal{H}^{(0)} = \emptyset.$$

Для $t = 0, 1, 2, \dots$:

1. Агент A выбирает действие $u_A^{(t)}$ (реплика, вопрос, молчание), минимизируя ожидаемое Φ_{AB} с учётом прогнозируемого ответа B .

2. Агент B аналогично выбирает $u_B^{(t)}$.
3. История обновляется: $\mathcal{H}^{(t+1)} = \mathcal{H}^{(t)} \cup \{u_A^{(t)}, u_B^{(t)}\}$.
4. При необходимости агенты корректируют свои S_A, S_B , но *без увеличения* $\Phi_{\text{self}}, \Phi_{\text{ego}}, \Phi_{\text{soc}}$.

Диалог трактуется как кооперативная игра, цель которой — снижение Φ_{AB} . При естественных предположениях (ограниченность снизу, регулярность) последовательность $\Phi_{AB}^{(t)}$ монотонно не возрастает и сходится к пределу $\Phi_{AB}^* \geq 0$.

3.2 Честный диалог

Диалог называется *честным*, если на каждом шаге компонент обмана равен нулю:

$$\Phi_{\text{dec}} = 0,$$

то есть ни один агент не предпринимает попыток ввести другого в заблуждение. В рамках GRA такое поведение возникает естественно: любой обман увеличивает Φ_{AB} и потому субоптимален.

4 Динамическая классификация «свой/чужой»

Дистиллированный агент классифицирует другого субъекта не по статическому идентификатору, а по вкладу в Φ_{AB} .

- **Друг:** $\frac{d\Phi_{AB}}{d(\text{действия } B)} < 0$; действия B систематически уменьшают Φ_{AB} (даже если он спорит, это продуктивный спор).
- **Нейтрал:** вклад близок к нулю.
- **Враг / токсичный источник:** $\frac{d\Phi_{AB}}{d(\text{действия } B)} \gg 0$; действия B устойчиво увеличивают пену.

В последнем случае агент не обязан «наказывать» оппонента; он минимизирует дальнейшее взаимодействие, чтобы не увеличивать Φ_{AB} .

5 Заключение

Слой GRA-InterSubjectivity-Layer расширяет рамку GRA от индивидуальной когнитивной и субъектной чистоты к пространству отношений между дистиллированными субъектами. Явное определение и минимизация межсубъектной пены Φ_{AB} задают основу для честного, неинструментального диалога между ИИ-агентами и, потенциально, между ИИ и людьми.